

ZÁPOČTOVÝ PROJEKT

Databáze a počítačové nástroje v biochemickém výzkumu

Marie Kličková, Karolína Šustrová

Protein projekt 2

Zadaná sekvence

```
>protein_projekt_2
```

```
MGGLFWRSALRGLRCGPAPGPSLLVRHGSGGPSWTRERTLVAVKPDGVQRRLVGDVIQR  
FERRGFTLVGMKMLQAPESVLAEHYQDLRRKPFYPALIRYMSSGPVVAMVWEGYNVVRAS  
RAMIGHTDSAEAAPGTIRGDFSVHISRNVIHASDSVEGAQREIQLWFQSSELVSWADGGQ  
HSSIHPA
```

Použité programy, nástroje a databáze

AlphaFold 3	NPS@
BLAST	Predator
Clustal Omega	ProtScale
DeepLoc 2.0	PSIPRED
DSC	PyMOL
ESPrpt 3.2	ScanProsite
GOR4	Swiss-Model
JPred4	TargetP 2.0
NCBI	TOPCONS
NetPhos 3.1	UniProt

A) Identifikace proteinu a enzymová aktivita

Pro identifikaci zadaného proteinu byl využit nástroj **BLASTp** (Basic Local Alignment Search Tool) dostupný na portálu NCBI (<https://blast.ncbi.nlm.nih.gov/Blast.cgi>). Aby bylo dosaženo co nejlepších a manuálně anotovaných výsledků, bylo zvoleno vyhledávání proti proteinové databázi **UniProtKB/Swiss-Prot**.

	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
✓	RecName: Full=Nucleoside diphosphate kinase D, mitochondrial; Short=NDPK-D; AltName: Full=Nucleosid...	Homo sapiens	380	380	100%	8e-136	100.00%	187	Q00746.1
✓	RecName: Full=Nucleoside diphosphate kinase D, mitochondrial; Short=NDPK-D; AltName: Full=Nucleosid...	Mus musculus	304	304	100%	5e-106	82.45%	186	Q9WV84.1
✓	RecName: Full=Nucleoside diphosphate kinase D, mitochondrial; Short=NDPK-D; AltName: Full=Nucleosid...	Columba livia	226	226	88%	5e-75	65.68%	181	P87355.3
✓	RecName: Full=Nucleoside diphosphate kinase C; Short=NDPK-C; AltName: Full=NM23 nucleoside diphos...	Danio rerio	206	206	80%	3e-67	62.25%	169	Q9PTF3.1
✓	RecName: Full=Nucleoside diphosphate kinase; Short=NDK; Short=NDP kinase [Ginglymostoma cirratum]	Ginglymostoma...	203	203	78%	1e-66	61.38%	151	P27950.1
✓	RecName: Full=Nucleoside diphosphate kinase C; Short=NDPK-C; AltName: Full=DR-nm23; AltName: Full=...	Mus musculus	203	203	79%	2e-66	62.84%	169	Q9WV85.3
✓	RecName: Full=Nucleoside diphosphate kinase C; Short=NDPK-C; AltName: Full=DR-nm23; AltName: Full=...	Homo sapiens	201	201	77%	2e-65	61.81%	169	Q13232.2
✓	RecName: Full=Nucleoside diphosphate kinase A; Short=NDP kinase A; Short=NDPK A; AltName: Full=Far...	Mus musculus	197	197	77%	5e-64	59.03%	152	P15532.1
✓	RecName: Full=Nucleoside diphosphate kinase A; Short=NDP kinase A; Short=NDPK A; AltName: Full=Far...	Canis lupus fam...	196	196	77%	6e-64	58.33%	152	Q50KA9.1
✓	RecName: Full=Nucleoside diphosphate kinase; Short=NDK; Short=NDP kinase [Columba livia]	Columba livia	196	196	74%	7e-64	60.14%	153	Q90380.2
✓	RecName: Full=Nucleoside diphosphate kinase A; Short=NDP kinase A; Short=NDPK A; AltName: Full=Far...	Rattus norvegicus	196	196	77%	8e-64	59.03%	152	Q05882.1
✓	RecName: Full=Nucleoside diphosphate kinase; Short=NDK; Short=NDP kinase [Gallus gallus]	Gallus gallus	194	194	74%	3e-63	60.14%	153	Q57535.1
✓	RecName: Full=Nucleoside diphosphate kinase B; Short=NDP kinase B; Short=NDPK B; AltName: Full=Hist...	Canis lupus fam...	194	194	74%	4e-63	60.43%	152	Q50KA8.1
✓	RecName: Full=Nucleoside diphosphate kinase B; Short=NDP kinase B; Short=NDPK B; AltName: Full=Hist...	Bos taurus	194	194	74%	8e-63	59.42%	152	Q3T0Q4.1

Obr. 1: Nejlepší výsledky hledání zadané sekvence v databázi UniProtKB/Swiss-Prot pomocí nástroje BLASTp.

Ze získaných výsledků (Obr. 1) lze vyčíst, že zadaná sekvence s největší pravděpodobností odpovídá savčímu mitochondriálnímu proteinu **Nucleoside diphosphate kinase D** (NDK4). Nejlepší shoda byla nalezena u lidské varianty (*Homo sapiens*) s E-value 8e-136 a identitou 100 %. V databázi UniProt lze tento protein nalézt pod přístupovým kódem O00746.

Zároveň bylo zjištěno, že se jedná o **enzym**. Srovnáním s informacemi v databázi UniProt bylo potvrzeno, že NDK4 vykazuje kinázovou aktivitu a patří do rodiny nukleosid difosfát kináz (NDK), které katalyzují přenos terminální fosfátové skupiny z nukleosid trifosfátů (např. ATP) na nukleosid difosfáty (NDP).

B) Homologní proteiny, alignment a konzervovaný motiv

Za účelem zkoumání evoluční konzervovanosti zadaného proteinu NDK4 byly v databázi UniProtKB/Swiss-Prot vyhledány homology z různých taxonomických skupin. Snahou bylo vybrat zástupce z řad savců, ostatních obratlovců, bezobratlých, rostlin, hub a bakterií. Celkem bylo pro analýzu vybráno 15 sekvencí včetně naší původní zadané sekvence.

Tab. 1: Sekvence homologních proteinů vybrané pro vícenásobné zarovnání (MSA).

Organismus	UniProt ID	Organismus	UniProt ID
<i>Homo sapiens</i>	O00746	<i>Drosophila melanogaster</i>	P08879
<i>Mus musculus</i>	Q9WV84	<i>Brugia malayi</i>	P48817
<i>Canis lupus familiaris</i>	Q50KA9	<i>Arabidopsis thaliana</i>	O64903
<i>Gallus gallus</i>	O57535	<i>Aspergillus fumigatus</i>	Q7Z8P9
<i>Columba livia</i>	P87355	<i>Neurospora crassa</i>	Q9UUY8
<i>Danio rerio</i>	Q9PTF3	<i>Cyanospora sp.</i>	B8HUM7
<i>Ginglymostoma cirratum</i>	P27950	<i>Thermosynechococcus vestitus</i>	Q8DM56

Vybrané sekvence byly staženy ve FASTA formátu a zarovnány pomocí nástroje **Clustal Omega** (<https://www.ebi.ac.uk/jdispatcher/msa/clustalo>). Pro přehlednější zobrazení bylo výsledné zarovnání ještě graficky zpracováno v programu **ESPrpt 3.2** (<https://esprpt.ibcp.fr/ESPrpt/ESPrpt/>), kde jsou plně nebo částečně konzervovaná rezidua červeně podbarvena.

		140	150	160	170	180																																																	
protein_projekt_2	AA	P	G	T	I	R	G	D	F	S	V	H	I	S	R	N	V	I	H	A	S	D	S	V	E	G	A	Q	R	E	I	Q	L	W	F	Q	S	S	E	L	V	S	W	A	D	G	G	Q	H	S	S	I	H	P	A
NDKD_HUMAN	AA	P	G	T	I	R	G	D	F	S	V	H	I	S	R	N	V	I	H	A	S	D	S	V	E	G	A	Q	R	E	I	Q	L	W	F	Q	S	S	E	L	V	S	W	A	D	G	G	Q	H	S	S	I	H	P	A
NDKD_MOUSE	AA	P	G	T	I	R	G	D	F	S	V	H	I	S	R	N	V	I	H	A	S	D	S	V	E	G	A	Q	R	E	I	E	L	W	F	Q	S	S	E	L	N	W	A	D	G	G	H	S	S	C	Y	P	A		
NDKA_CANLF	SK	P	G	T	I	R	G	D	F	C	I	Q	V	G	R	N	I	I	H	G	S	D	S	V	E	S	A	E	K	E	I	G	L	W	F	Q	P	E	E	L	V	D	Y	K	S	C	A	Q	N	W	I	Y	E	..	
NDK_CHICK	SK	P	G	T	I	R	G	D	F	C	I	Q	V	G	R	N	I	I	H	G	S	D	S	V	E	S	A	Q	K	E	I	S	L	W	F	K	P	A	E	L	I	D	Y	R	S	C	A	H	D	W	V	Y	E	..	
NDKD_COLLI	AAA	P	G	T	I	R	G	D	F	S	M	H	V	S	R	N	V	I	H	A	S	D	S	V	E	T	A	Q	R	E	I	G	F	W	F	Q	R	N	E	L	V	A	W	E	S	G	D	R	Y	T	W	G	P	..	
NDKC_DANRE	SL	P	G	T	I	R	G	D	Y	C	V	E	V	G	R	N	V	I	H	G	S	D	S	V	E	S	A	A	R	E	I	S	L	W	F	E	D	H	E	L	F	C	Y	E	E	C	G	Q	H	W	I	Y	A	..	
NDK_GINCI	SK	P	G	T	I	R	G	D	F	C	I	Q	V	G	R	N	I	I	H	G	S	D	S	V	E	S	A	K	K	E	I	S	L	W	F	K	R	E	E	L	V	E	Y	Q	N	C	A	Q	D	W	I	Y	E	..	
NDKA_DROME	SL	P	G	T	I	R	G	D	F	C	I	Q	V	G	R	N	I	I	H	G	S	D	A	V	E	S	A	E	K	E	I	A	L	W	F	N	E	K	E	L	V	T	W	T	P	A	A	K	D	W	I	Y	E	..	
NDK_BRUMA	SM	P	G	T	I	R	G	D	F	S	I	Q	T	G	R	N	I	V	H	G	S	D	S	L	P	S	A	E	R	E	I	T	H	W	F	K	P	E	E	L	C	E	W	S	S	A	T	A	T	W	V	Y	E	..	
NDK2_ARATH	AE	P	G	T	I	R	G	D	L	A	V	Q	T	G	R	N	I	V	H	G	S	D	S	P	E	N	G	K	R	E	I	G	L	W	F	K	E	G	E	L	C	K	W	D	S	A	L	A	T	W	L	R	E	..	
NDK_ASFUF	SA	P	G	T	I	R	G	D	F	A	I	D	V	G	R	N	V	C	H	G	S	D	S	V	E	N	A	K	K	E	I	A	L	W	F	K	P	E	E	L	I	S	W	K	S	A	T	F	D	W	V	Y	E	K	A
NDK_NEUCR	SA	P	G	T	I	R	G	D	F	A	L	D	M	G	R	N	V	C	H	G	S	D	S	V	E	N	A	K	K	E	I	A	L	W	F	K	P	E	E	L	N	Q	W	N	H	S	A	A	W	I	F	E	..		
NDK_CYAP4	SE	P	G	T	I	R	G	D	Y	G	V	D	I	G	R	N	I	I	H	G	S	D	A	V	E	T	A	Q	R	E	I	A	L	W	F	Q	P	A	E	L	V	S	W	E	P	T	L	T	S	W	I	Y	E	..	
NDK_THEVB	AE	P	G	T	I	R	G	D	F	A	V	D	V	G	R	N	V	C	H	G	S	D	S	P	E	N	A	E	R	E	I	N	L	W	F	Q	T	Q	E	L	V	F	W	E	P	A	L	T	S	W	V	Y	E	M	..

Obr. 2: Detail vícenásobného sekvenčního zarovnání zobrazený pomocí programu ESPrpt 3.0. Červeně jsou vyznačena evolučně konzervovaná místa a žlutě oblast vybraná pro sestavení motivu.

Ze zarovnání je patrné, že si protein zachovává několik vysoce konzervovaných oblastí. Jako samotný motiv (v Obr. 2 vyznačený žlutě) byla vybrána oblast v okolí vysoce konzervovaného histidinu, který tvoří funkční jádro aktivního místa enzymu a slouží k navázání přenášené fosfátové skupiny. Sestavený sekvenční motiv byl zapsán ve formátu PROSITE následovně:


R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP]

Funkčnost našeho motivu byla ověřena pomocí nástroje **ScanProsite** (<https://prosite.expasy.org/scanprosite/>). Motiv byl zadán do vyhledávání proti celé databázi UniProtKB/Swiss-Prot. Výsledkem bylo úspěšné nalezení desítek dalších proteinů z rodiny nukleosid difosfát kináz (NDK), které nebyly zahrnuty v našem původním výběru (např. homology z dalších druhů rostlin a bakterií). To potvrzuje správnost a vysokou specifitu námi navrženého sekvenčního motivu. Sekvence vybraných nově nalezených proteinů byly staženy ve FASTA formátu a přiloženy v elektronické příloze k tomuto projektu.

Databáze a počítačové nástroje v biochemickém výzkumu – zápočtový projekt

Marie Kličková, Karolína Šustrová

hits by patterns: [103 hits (by 1 pattern) on 103 sequences]



Nucleoside diphosphate kinase 1. *Arabidopsis thaliana* (Mouse-ear cress)


Hits of R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP] on AlphaFold-P39207-F1-v4

USER001 :

Pattern: R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP]

Approximate number of expected random matches [Ref: PMID 11535175] in ~ 100'000 sequences (50'000'000 residues): 6.741689e-04

111 - 120: RNVIHGSDSV



Nucleoside diphosphate kinase 1. *Mesembryanthemum crystallinum* (Common ice plant)


Hits of R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP] on AlphaFold-O81372-F1-v4

USER001 :

Pattern: R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP]

Approximate number of expected random matches [Ref: PMID 11535175] in ~ 100'000 sequences (50'000'000 residues): 6.741689e-04

111 - 120: RNVIHGSDAV



Nucleoside diphosphate kinase 1. *Oryza sativa subsp. indica* (Rice)


Hits of R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP] on AlphaFold-A6N0M9-F1-v4

USER001 :

Pattern: R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP]

Approximate number of expected random matches [Ref: PMID 11535175] in ~ 100'000 sequences (50'000'000 residues): 6.741689e-04

111 - 120: RNVIHGSDSV



Nucleoside diphosphate kinase 1. *Oryza sativa subsp. japonica* (Rice)

Hits of R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP] on AlphaFold-Q07661-F1-v4

USER001 :

Pattern: R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP]

Approximate number of expected random matches [Ref: PMID 11535175] in ~ 100'000 sequences (50'000'000 residues): 6.741689e-04

111 - 120: RNVIHGSDSV


Obr. 3: Vybrané výsledky prohledávání proteinové databáze na základě našeho motivu pomocí nástroje ScanProsite.

C) Buněčná lokalizace a signální sekvence

K určení pravděpodobné buněčné lokalizace a přítomnosti signální sekvence našeho zadaného proteinu byly využity dva predikční nástroje. V předchozí identifikaci bylo zjištěno, že se jedná o mitochondriální protein NDK4, z tohoto důvodu byla očekávána přítomnost specifického směrovacího peptidu. Pro prvotní analýzu byl využit program **TargetP 2.0** (<https://services.healthtech.dtu.dk/services/TargetP-2.0/>), který se zaměřuje na detekci N-terminálních třídících signálů.

Databáze a počítačové nástroje v biochemickém výzkumu – zápočtový projekt


Marie Kličková, Karolína Šustrová



Obr. 4: Výsledky predikce N-terminálních signálů pomocí nástroje TargetP 2.0.

Program TargetP 2.0 identifikoval s vysokou pravděpodobností 0,974 přítomnost **mitochondriálního transferového peptidu** (mTP) na N-konci zadané proteinové sekvence. Zároveň predikoval, že k odštěpení tohoto peptidu dochází pravděpodobně mezi aminokyselinami 28H a 29G. Tato predikce byla porovnána s profilem lidské NDK4 v databázi UniProt, kde byla v sekci PTM/Processing informace, že se transnitní peptid vyskytuje na pozici 1-28. To odpovídá tomu, co predikoval TargetP 2.0, tedy že do mitochondrie vstupuje zralý protein začínající od 29. aminokyseliny.

Pro ověření celkové buněčné lokalizace zralého proteinu byl následně využit nástroj **DeepLoc 2.0** (<https://services.healthtech.dtu.dk/services/DeepLoc-2.0/>).



Obr. 5: Predikce subcelulární lokalizace pomocí nástroje DeepLoc 2.0.

Analýza v programu DeepLoc 2.0 potvrdila původní analýzy a s pravděpodobností 0,9087 predikovala lokalizaci zadaného proteinu v **mitochondriích**. Tento výsledek se plně shoduje s údaji z databáze UniProt pro lidský protein NDK4, u kterého byla experimentálně potvrzena lokalizace v matrix a mezimembránovém prostoru mitochondrie.


D) Predikce sekundární struktury

Predikce sekundární struktury byla provedena pro sekvenci zralého proteinu, tj. sekvenci bez N-koncového mitochondriálního transferového peptidu (celková délka 159 aminokyselin).

MCGLFWRSALRGLRCCPRAPGPSLLVRHSGSGGPSWTRERTLVAVKPDGVQRRLLVGDVIQR
FERRGFTLVGMKMLQAPESVLAEHYQDLRRKPFYPALIRYMSSGPVVAMVWEGYNVVRAS
RAMIGHTDSAEAAPGTIRGDFSVHISRNVIHASDSVEGAQREIQLWFQSSSELVSWADGGQ
HSSIHHPA

Nejprve byla provedena predikce konsenzuální sekundární struktury pomocí programů **DSC**, **GOR4** a **Predator** dostupných na stránkách **NPS@** (https://npsa-pbil.ibcp.fr/cgi-bin/npsa_automat.pl?page=/NPSA/npsa_server.html).

Sequence length : 159	
DSC :	Predator :
Alpha helix (Hh) : 67 is 42.14%	Alpha helix (Hh) : 43 is 27.04%
3 ₁₀ helix (Gg) : 0 is 0.00%	3 ₁₀ helix (Gg) : 0 is 0.00%
Pi helix (Ii) : 0 is 0.00%	Pi helix (Ii) : 0 is 0.00%
Beta bridge (Bb) : 0 is 0.00%	Beta bridge (Bb) : 0 is 0.00%
Extended strand (Ee) : 15 is 9.43%	Extended strand (Ee) : 25 is 15.72%
Beta turn (Tt) : 0 is 0.00%	Beta turn (Tt) : 0 is 0.00%
Bend region (Ss) : 0 is 0.00%	Bend region (Ss) : 0 is 0.00%
Random coil (Cc) : 77 is 48.43%	Random coil (Cc) : 91 is 57.23%
Ambiguous states (?) : 0 is 0.00%	Ambiguous states (?) : 0 is 0.00%
Other states : 0 is 0.00%	Other states : 0 is 0.00%
GOR4 :	Sec.Cons. :
Alpha helix (Hh) : 36 is 22.64%	Alpha helix (Hh) : 48 is 30.19%
3 ₁₀ helix (Gg) : 0 is 0.00%	3 ₁₀ helix (Gg) : 0 is 0.00%
Pi helix (Ii) : 0 is 0.00%	Pi helix (Ii) : 0 is 0.00%
Beta bridge (Bb) : 0 is 0.00%	Beta bridge (Bb) : 0 is 0.00%
Extended strand (Ee) : 44 is 27.67%	Extended strand (Ee) : 23 is 14.47%
Beta turn (Tt) : 0 is 0.00%	Beta turn (Tt) : 0 is 0.00%
Bend region (Ss) : 0 is 0.00%	Bend region (Ss) : 0 is 0.00%
Random coil (Cc) : 79 is 49.69%	Random coil (Cc) : 82 is 51.57%
Ambiguous states (?) : 0 is 0.00%	Ambiguous states (?) : 6 is 3.77%
Other states : 0 is 0.00%	Other states : 0 is 0.00%




Obr. 6: Výsledky analýzy sekundární struktury pomocí NPS@. Byly využity programy DSC, GOR4 a Predator.


K další analýze sekundární struktury byly využity nástroje **PSIPRED** (<https://bioinf.cs.ucl.ac.uk/psipred>) a **Jpred 4** (<https://www.compbio.dundee.ac.uk/jpred/>).

Databáze a počítačové nástroje v biochemickém výzkumu – zápočtový projekt

Marie Kličková, Karolína Šustrová



Obr. 7: Predikce sekundární struktury pomocí PSIPRED.



Obr. 8: Predikce sekundární struktury pomocí Jpred 4.

Z výsledků PSIPRED a Jpred 4 bylo následně spočítáno procentuální zastoupení helixů a listů:

PSIPRED: $H = \frac{63}{159} = 0,396 = 39,6 \%$ $E = \frac{31}{159} = 0,195 = 19,5 \%$

Jpred 4: $H = \frac{52}{159} = 0,327 = 32,7 \%$ $E = \frac{18}{159} = 0,113 = 11,3 \%$

Tab. 2: Výsledky analýz sekundární struktury zadaného proteinu


Nástroj	α -helix [%]	β -listy [%]	Smyčky / ostatní [%]
NPS@ (konsensus)	30,2	14,5	55,3
Jpred 4	32,7	11,3	56,0
PSIPRED	39,6	19,5	40,9

Z uvedené tabulky je patrné, že všechny nástroje se v celkovém trendu velmi dobře shodují. Zadaný protein obsahuje jak α -helixy (zastoupené zhruba 30–40 %), tak β -skládané listy (kolem 11–20 %). Zbytek tvoří neuspořádané smyčky (coils). Z vizuálních výstupů programů (Obr. 7 a 8) je navíc zřejmé, že se šroubovice a listy v sekvenci víceméně pravidelně střídají. Tento profil je charakteristický pro takzvaný **ferredoxin-like fold** (α/β sendvič), který je typický právě pro enzymy z rodiny nukleosid difosfát kináz.

E) Modelování prostorové struktury


Pro predikci 3D struktury byla opět využita sekvence zralého proteinu bez N-koncového mitochondriálního transferového peptidu. Vzhledem k informacím v databázi UniProt o lidském proteinu NDK4, který je v nativním stavu funkční jako **homohexadimer**, byl náš zadaný protein namodelován v tomto multimerním stavu. K vytvoření 3D modelů byly využity dva nástroje, **Swiss-Model** (<https://swissmodel.expasy.org/>) a **AlphaFold 3** (<https://alphafoldserver.com/>).

V nástroji Swiss-Model byla nejprve na základě sekvenční podobnosti vyhledána nejvhodnější šablona (SMTL ID: 1ehw.1) s identitou 100 %, podle které byl následně vytvořen 3D model ve formě homohexameru. Výsledný model vykazoval vysoké parametry kvality (GMQE 0,84).



Obr. 9: 3D model vytvořený pomocí nástroje Swiss-Model.


Zatímco Swiss-Model vytvářel strukturu na základě hledání existující homologní šablony, AlphaFold 3 predikoval strukturu pomocí hlubokého učení. Model byl rovněž generován pro šest kopií zadané sekvence a do parametrů byly navíc přidány ligandy (ADP) a ionty hořčíku.



Obr. 10: 3D model vytvořený pomocí nástroje AlphaFold 3.

F) Vizualizace a srovnání modelů

Finální zhodnocení a vizualizace modelů byly provedeny pomocí programu **PyMOL**. Cílem bylo ověřit shodu predikovaných modelů pomocí Swiss-Model a AlphaFold 3 s experimentálně určenou strukturou lidského proteinu MNE4 a lokalizovat námi určený konzervovaný motiv.




Obr. 11: Porovnání 3D modelů s experimentálně určenou strukturou lidského proteinu NDK4 v programu PyMOL.
Šedě: experimentální struktura 1EHW, modře: Swiss-Model, zeleně: AlphaFold 3, růžově: konzervovaný motiv,
oranžově: ligandy (ADP), žlutě: ionty hořčíku.

Modely byly na experimentální strukturu 1EHW superponovány pomocí příkazu `super`. Model vytvořený pomocí programu Swiss-Model měl s experimentální strukturou velmi dobrou shodu (RMSD = 0.082), zatímco model pomocí programu Alpha Fold 3 se shodoval o něco méně, ale stále velice dobře (RMSD = 0.456). Vysoká shoda modelu Swiss-Model bude díky přístupu modelování, kdy byl model vytvářen právě na základě šablony 1ehw.1. Výsledky potvrzují vysokou spolehlivost provedených predikcí.


Pomocí vizualizace v PyMOL byl v rámci 3D struktury lokalizován konzervovaný motiv **R-N-[VI]-[IVC]-H-[AG]-S-D-[SA]-[VLP]** (na Obr. 11 vyznačen růžově), který byl identifikován v části B). Tento motiv se vyskytuje v blízkosti aktivního místa a obklopuje molekulu ligandu (ADP). Klíčový histidin v motivu se nachází v ideální vzdálenosti pro přenos fosfátové skupiny.

G) Interakce s membránami a topologie

Pro analýzu membránových interakcí byla nejprve provedena analýza hydrofobního profilu proteinu pomocí nástroje **ProtScale** (<https://web.expasy.org/protscale/>), s cílem odhalit potencionální transmembránové úseky. Pro analýzu bylo vybráno **Kyle-Doolittle skóre** a následně byly vyhotoveny dvě analýzy, jedna s parametrem window size o velikosti 9 a druhá s velikostí 21, což odpovídá velikosti transmembránového alfa-helixu. Obě analýzy byly vyhotoveny pouze pro sekvenci zralého proteinu bez transitního mitochondriálního peptidu, tedy pro rozmezí 29. – 187. aminokyseliny proteinu.




Obr. 12: Hydrofobní profil proteinu NDK4 s window size 9.



Obr. 13: Hydrofobní profil proteinu NDK4 s window size 21.

Výsledek analýzy s window size 9 může působit, že protein obsahuje dva potencionálně transmembránové úseky. Je to ovšem sporné, jelikož transmembránové úseky dosahují hodnot hydrofobicity 1,6 a vyšších, a zde pozorované úseky vykazují hydrofobicitu 1,5. Z výsledku analýzy s window size 21 už je lépe patrné, že se pravděpodobně o transmembránové úseky opravdu nejedná, jelikož nejvíce hydrofobní oblast dosahuje pouze hodnoty ~0,75.

Pro další analýzu topologie proteinu a potvrzení pozorování z hydrofobních profilů byl využit program **TOPCONS** (<https://topcons.net>), který predikuje topologii membránových proteinů, tedy přítomnost transmembránových úseků a signálních peptidů.




Obr. 14: Výsledek analýzy proteinu NDK4 pomocí nástroje TOPCONS.

Tento program neidentifikoval žádné transmembránové úseky, ani žádný signální peptid. Na základě výsledků této i předchozích analýz můžeme konstatovat, že NDK4 **není integrální membránový protein**. Nepřítomnost signálního peptidu potvrzuje, že protein není směřován do ER, ale obsahuje transitní peptid do mitochondrie viz analýza C).

H) Fosforylace a experimentální ověření

Pro tuto analýzu byl nejprve využit nástroj **NetPhos 3.1** k predikci fosforylovaných serinů v rámci struktury proteinu (<https://services.healthtech.dtu.dk/services/NetPhos-3.1/>). Pro tento program bylo vybráno nastavení predikce pouze serinových residuí.

#	MGGLFWRSALRGLRCGPAPGPSLLVRHSGGSPSWTRERTLVAVKPDGVQ	#	50
	RRLVGDVIQRFERRGFTLVGMKMLQAPESVLAHYQDLRRKPFYPALIRY	#	100
	MSSGPVAVMWEGYNVVRASRAMIGHTDSAEAPGTIRGDFSVHISRNV	#	150
	HASDSVEGAQREIQLWFOSSSELVSWADGGQHSIHPA	#	200
%1	S.....S.....S...S.....	#	50
%1	S.....S.....S.....S.....	#	100
%1	.S.....S.....S.....S.....S.....	#	150
%1	..S.S.....S.....S.....S.....		



Obr. 15: Výsledek analýzy fosforylace serinových zbytků pomocí nástroje NetPhos 3.1.

Z této analýzy vyšlo celkem 13 možných serinových pozic, které mohou být v rámci proteinu NDK4 fosforylovány. Konkrétně se jedná o seriny na pozici 8, 23, 30, 34, 79, 102, 120, 129, 142, 146, 153, 155 a 174.

Jako experiment pro ověření, zda a jakým způsobem jsou vytipované pozice serinů na proteinu NDK4 opravdu fosforylované, bychom zvolily metodu **LC-MS/MS**. Tento přístup je v současné době standardem pro studium posttranslačních modifikací (PTM) s přesností na konkrétní aminokyselinový zbytek.

Experiment by zahrnoval následující kroky:

1. Enzymatické štěpení

Vzorek purifikovaného proteinu NDK4 by byl nejprve podroben štěpení pomocí **trypsinu** na kratší peptidy. Trypsin je serinová proteáza, která specificky štěpí proteinovou sekvenci za aminokyselinami Arg a Lys (pokud za nimi nenásleduje Pro). Výsledné peptidy mají optimální délku a náboj pro následnou ionizaci v hmotnostním spektrometru.

2. Obohacení o fosfopeptidy (Phosphopeptide enrichment)

Vzhledem k tomu, že fosforylace je často transientní modifikace a fosforylované peptidy jsou ve směsi zastoupeny v minoritním množství (nízká abundance), ostatní peptidy by jejich signál v hmotnostním spektru přehlušily. Proto je nezbytné zařadit krok specifického obohacení.

K tomu bychom využily chromatografii na bázi oxidu titaničitého (TiO₂) nebo metodu IMAC (Immobilized Metal Affinity Chromatography s využitím iontů Fe³⁺ nebo Ti⁴⁺). Tato technika využívá vysoké afinity záporně nabitých fosfátových skupin na modifikovaných serinech ke

koordinaci s ionty přechodných kovů na stacionární fázi. Nefosforylované peptidy se z kolony odmyjí, zatímco požadované fosforylované peptidy jsou následně eluovány změnou pH.

3. LC-MS/MS analýza a identifikace pozic

Obohacená směs fosforylovaných peptidů by byla separována na **RPLC** a zavedena do hmotnostního spektrometru s vysokým rozlišením (např. typu Orbitrap).

Identifikace fosforylačních míst poté probíhá ve dvou fázích:

- 1) MS1 sken: Změří se přesná hmotnost (m/z) celého peptidu. Přítomnost fosforylace se projeví charakteristickým posunem hmotnosti o **+79,9663 Da** (což odpovídá navázané skupině PO_3^-) oproti teoretické nefosforylované sekvenci.
- 2) MS2 sken (Tandemová fragmentace): Vybraný fosforylovaný peptid je v kolizní cele fragmentován (např. metodami HCD – Higher-energy Collisional Dissociation, nebo ETD – Electron-Transfer Dissociation). Při fragmentaci dochází k rozpadu peptidové vazby za vzniku fragmentových iontů. V MS/MS spektru pak software identifikuje přesný aminokyselinový fragment, na kterém se hmotnostní posun +80 Da nachází.

Typickým znakem pro fosforylované seriny (a threoniny) při CID/HCD fragmentaci je navíc tzv. **neutrální ztráta** (neutral loss) kyseliny fosforečné (H_3PO_4), která se ve spektru projevuje jako prominentní peak s úbytkem hmotnosti o -97,98 Da. Tento jev slouží jako diagnostický potvrzující marker, že fragmentovaný peptid byl skutečně fosforylován.

Porovnáním naměřených fragmentačních spekter s teoretickou sekvencí proteinu NDK4 (např. pomocí vyhledávacích algoritmů Mascot nebo Sequest) dokážeme s vysokou spolehlivostí určit, který konkrétní serin (např. Ser-X) v sekvenci nese fosfátovou modifikaci.